

Prashant Choudhary

AI/ML Engineer | Python-Backend | LLM- & Agentensysteme
Trier, Deutschland | **Umzugsbereit** | prashantc592114@gmail.com | +49 179 1605929
LinkedIn | GitHub | Portfolio

Profil

AI/ML Engineer und M.Sc.-Student im Studiengang Natural Language Processing an der Universität Trier mit Berufserfahrung in **Python-/FastAPI-Backends** für öffentlich verfügbare AI-Produkte, **produktiven RAG-Systemen**, **agentischen Workflows** und Voice/IVR-Anwendungen. Praktische Erfahrung mit PyTorch, Hugging Face, LangGraph, Vektorsuche, Modellevaluation und lokaler LLM-Infrastruktur. Erfahrung über den gesamten AI-Backend-Lifecycle hinweg, von Daten-Ingestion und Retrieval bis zu Orchestrierung, Inferenz und Produktionsintegration. Gesucht wird eine Werkstudententätigkeit in AI/ML, Python Backend, NLP oder Generative AI.

Ausbildung

Universität Trier

M.Sc. Natural Language Processing

Trier, Deutschland

Apr. 2026 – voraussichtlich Sep. 2028

Uka Tarsadia University

B.Tech Artificial Intelligence & Data Science | CGPA: 7,26/10

Bardoli, Indien

2021 – 2025

Berufserfahrung

EnactOn Technologies / Proposal.biz

Junior AI/ML Backend Engineer
AI Prompt Engineer, Praktikum

Surat, Indien

Juli 2025 – Nov. 2025
Dez. 2024 – Juli 2025

- Entwicklung von **Python-/FastAPI-AI-Backends** für öffentlich verfügbare Produkte, darunter **produktive RAG-Pipelines**, agentische Workflows und sprachbasierte IVR-Systeme für Patienten- und Serviceanwendungen.
- Mitwirkung am frühen AI-Backend von **Proposal.biz**: Aufbau einer **Website-zu-Vektordaten-Pipeline**, die Kunden-URLs crawlt, Unternehmensinhalte extrahiert und verarbeitet und daraus abrufbaren Kontext für fundierte Angebotserstellung erzeugt.
- Entwicklung agentischer Workflows zur Angebotserstellung mit **Kontext-/State-Management**, Retrieval, Web-/Suchintegration und Bildgenerierung innerhalb mehrstufiger Dokumenterstellung und -bearbeitung.
- Integration von LLM-Providern, strukturiertem Prompting, Retrieval-Komponenten und Guardrails in produktive Services für zuverlässige, langlaufende AI-Workflows.

ALGOBRAIN AI

AI/ML Engineer, Praktikum

Remote, Indien

Sep. 2023 – Jan. 2024

- Entwicklung von Conversational-AI-Prototypen mit **Python, TensorFlow, Rasa und Dialogflow**, mit Fokus auf Intent-Erkennung, Dialogabläufe und Modell-/API-Integration.
- Aufbau und Evaluation ML-gestützter Automatisierungs- und Chatbot-Workflows für anwendungsnahe, kundenorientierte Szenarien.

Nothing

Community Product Tester

Remote

Feb. 2023 – heute

- Test von Vorabversionen von Software und Hardware sowie Dokumentation und Meldung von **150+ Produktproblemen und Edge Cases** zur Verbesserung von Release-Qualität und Stabilität.

Technische Kenntnisse

Programmierung & Backend: Python, FastAPI, REST APIs, SQL, PostgreSQL, SQLite, Supabase, Linux
Machine Learning & NLP: PyTorch, TensorFlow, scikit-learn, Hugging Face Transformers, Sentence Transformers, NLP, Deep Learning, Few-Shot Learning, Contrastive Learning, Modellevaluation
LLMs & Agentic AI: RAG, LangChain, LangGraph, CrewAI, Agno, Tool Calling, Prompt Engineering, Embeddings, Vektorsuche, Ollama, OpenAI/Gemini/Groq APIs
MLOps & Cloud: Docker, Git/GitHub, MLflow, AWS SageMaker, Google Vertex AI, Oracle OCI, Qdrant, ChromaDB

Ausgewählte AI/ML- & Open-Source-Projekte

SetFit Reproduction & Paper-Code Audit Python, PyTorch, Hugging Face, Sentence Transformers *2026*

- Eigenständige Reimplementierung der SetFit-Methode für Few-Shot-Textklassifikation ohne das offizielle SetFit-Paket, einschließlich deterministischem Sampling, kontrastivem Fine-Tuning des Sentence Encoders und nachgelagerter Klassifikation.
- Reproduktion des CR-MPNet-Ergebnisses über **10 unabhängige Läufe mit $88,61 \pm 1,61\%$ Genauigkeit**, gegenüber $88,5 \pm 1,9\%$ im Paper.
- Identifikation und experimentelle Validierung einer Abweichung zwischen der im Paper dokumentierten Lernrate und dem effektiven Verhalten der veröffentlichten Implementierung durch Quellcodeanalyse und kontrollierte Experimente.

PocketLLM Ecosystem Python, FastAPI, RAG, Ollama, Local LLMs, Supabase *2025 – heute*

- Aufbau und Pflege eines Open-Source-LLM-Ökosystems für Cloud- und lokale Assistenten, einschließlich **FastAPI-Backend** mit Provider-Abstraktion, Streaming-Inferenz, Model Discovery, verschlüsselten BYOK-Zugangsdaten und persistenter Konversationshistorie.
- Erweiterung um **PocketLLM Lite**: lokale/offline Inferenz, Ollama- und GGUF-Modellverwaltung, Dokument-Ingestion mit quellenbezogenem Retrieval, Tool Calling, Memories, Whisper-Transkription und lokalem OpenAI-kompatiblen Server.
- Ausbau des Hauptprojekts PocketLLM auf **66+ GitHub Stars und 11 Forks**.

AetherMind / Forge-1 Python, PyTorch, Transformers, CUDA *2026*

- Entwurf eines kompakten Decoder-only-Sprachmodell-Stacks mit einer **~125-Mio.-Parameter-Variante für Consumer-GPUs mit 4 GB VRAM**.
- Implementierung von RMSNorm, Grouped Query Attention, RoPE, SwiGLU und Weight Tying sowie eigener Trainings-, Inferenz- und Evaluationspipelines.
- Einsatz speichereffizienter Trainingsverfahren wie FP16 Mixed Precision, Gradient Checkpointing und Gradient Accumulation für hardwarebeschränkte Umgebungen.

Moltjobs AI-Produkt, LLM-gestützter Bewerbungsworkflow *2026 – heute*

- Aufbau einer AI-gestützten Bewerbungsplattform mit Lebenslauf-Erstellung/-Import, AI-gestützter Anpassung, überprüfbaren Änderungen, Bewerbungs-Tracking, Follow-ups, Interviewvorbereitung und analyseorientierten Workflows.
- Ausbau des Produkts auf **2.000+ Nutzer** bei fortlaufender Weiterentwicklung des vollständigen Bewerbungs- und Jobsuchprozesses.

Erfolge

- **Top 7 von 50 Teams**, Amalthea Hackathon 2024, IIT Gandhinagar; Entwicklung einer multilingualen AI-Healthcare-Lösung mit Voice-/IVR-Workflows auf Basis von Python, FastAPI, Dialogflow, Twilio, Gemini und PyTorch.
- Aufbau von Open-Source-AI-Systemen mit messbarer Nutzung, darunter **PocketLLM (66+ Stars, 11 Forks)** und **Moltjobs (2.000+ Nutzer)**.

Zertifizierungen

Oracle: OCI 2025 Data Science Professional; AI Vector Search Professional; OCI 2025 AI Foundations Associate

Machine Learning: Supervised Machine Learning: Regression and Classification, Coursera; High-Dimensional Data Analysis, HarvardX

Sprachen & Verfügbarkeit

Englisch: Fließend, IELTS Academic 7.5 **Deutsch:** B1, derzeit im Ausbau **Hindi:** Muttersprache
Status: M.Sc.-Student in Deutschland; verfügbar für studentische Beschäftigung | **Umzugsbereit**